




Metrics

Daniel Nogueira

dnogueira@ipca.pt

Metrics

Machine Learning Models




Reference: Input (Dataset)

Metrics

Machine Learning Models

Reference: Output

Classification Models




Metrics


Machine Learning Models

Classification Models


Decision Tree




Naive Bayes



Random Forest



Support Vector Machine




Machine Learning Models

Classification Models

Regression Models

Metrics

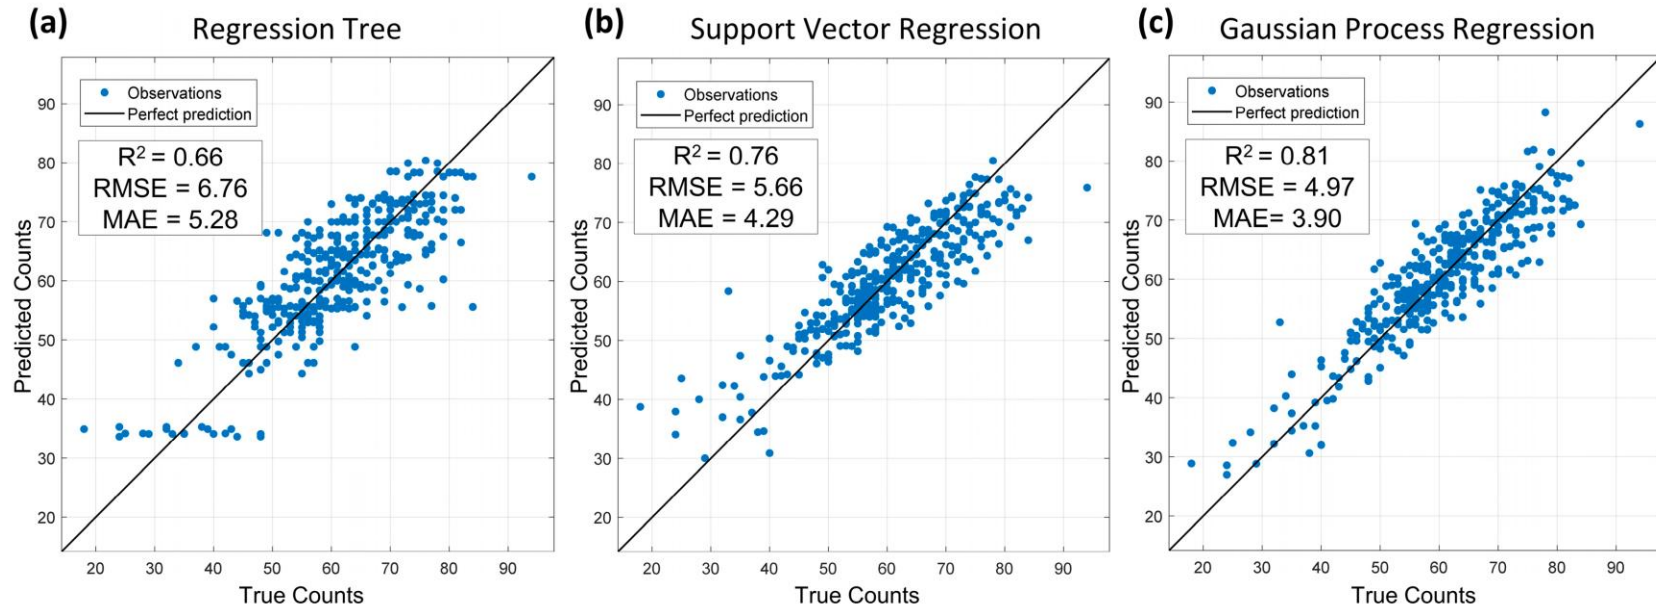


Metrics

Machine Learning Models

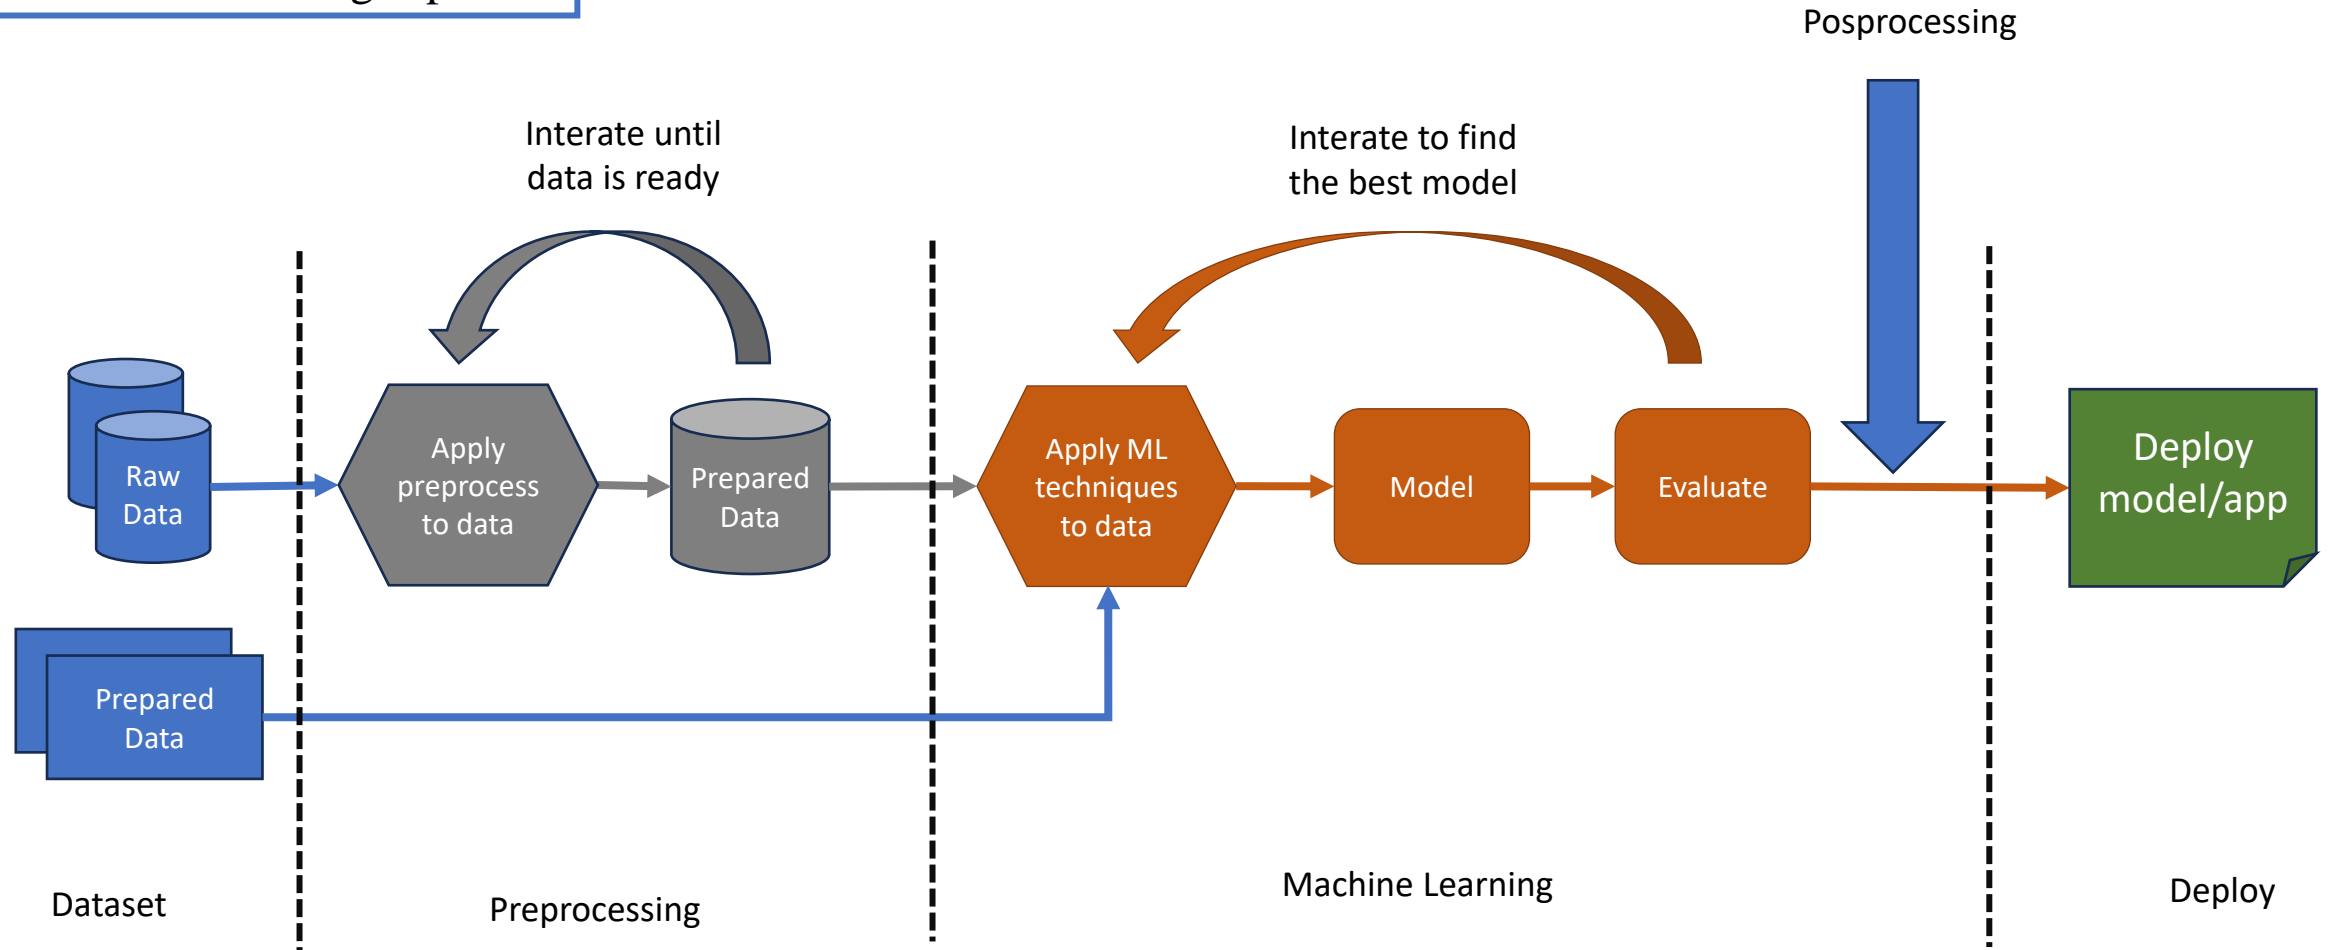
Classification Models

Regression Models






Metrics

Machine Learning Pipeline



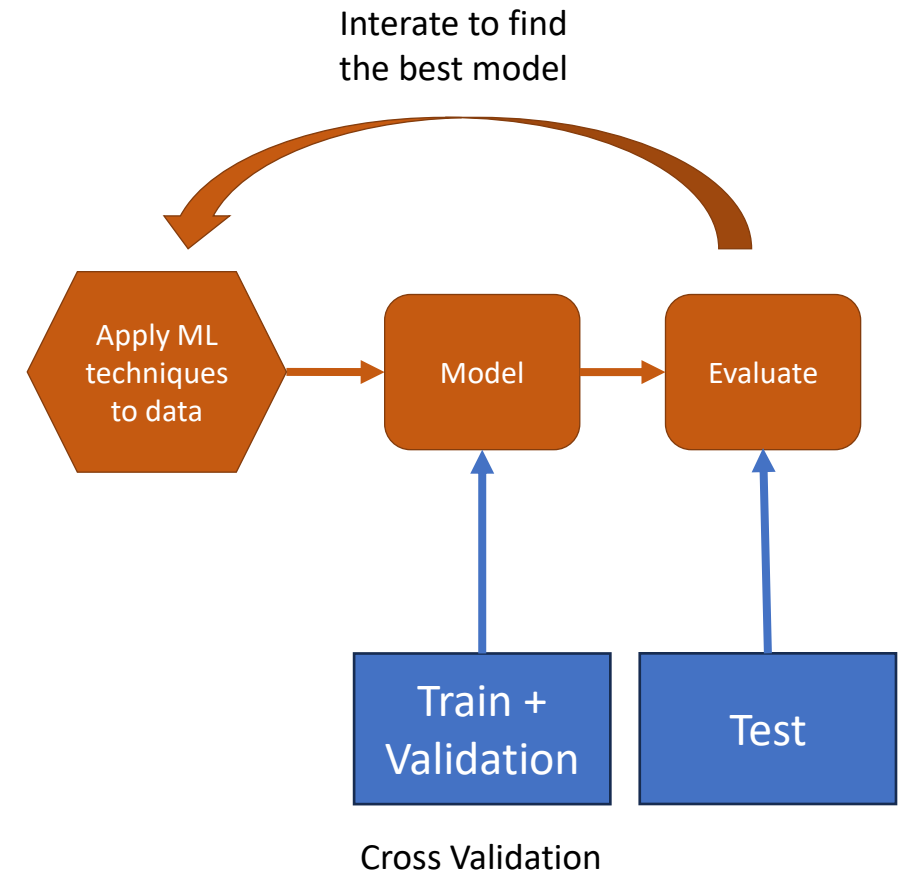


Metrics

Dataset



Metrics

Dataset



Metrics

Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



High Accuracy
High Precision????

Metrics

Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Metrics

Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Low Accuracy
Low Precision

Metrics

Accuracy

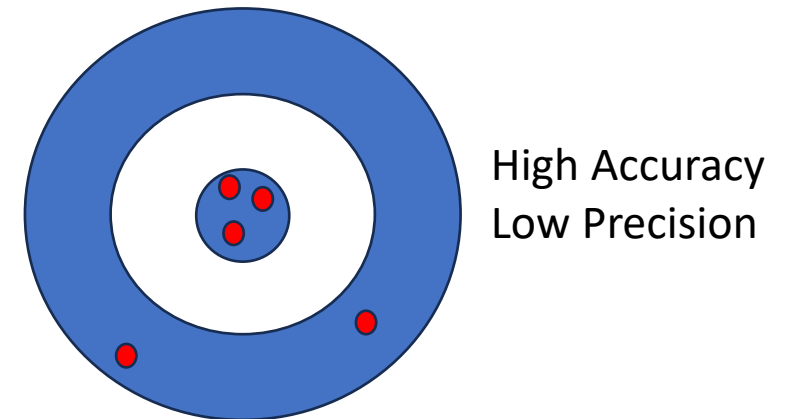
Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Metrics

Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision

Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo



Metrics

Accuracy


Accuracy mede o quão próximo o resultado está do valor real que você estava tentando alcançar. Em outras palavras, é o quão perto você atinge o que almeja.

Accuracy pode ser usada em uma instancia.

Precision


Precision mede a proximidade entre seus resultados.

Precision é usada ao longo do tempo







Metrics

TP – True Positive
 FP – False Positive
 TN – True Negative
 FN – False Negative



Metrics

		Predicted	
Actual			
			

		Predicted		
		Positive	Negative	
Actual	Positive	True positive(TP)	False Negative(FN)	Sensitivity or Recall or True Positive Rate= $TP/(TP+FN)$
	Negative	False Positive (FP)	True Negative(TN)	Specificity or True Negative Rate= $TN/(TN+FP)$
		Precision or Positive Predictive Value= $TP/(TP+FP)$	Negative Predictive Value= $FN/(FN+TN)$	Accuracy= $TP+TN/TP+TN+FP+FN$

Metrics

➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

Metrics

➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

➤ Precision (Precisão):


- **Definição:** A precisão mede a proporção de previsões positivas corretas em relação ao número total de previsões positivas feitas pelo modelo.
- **Foco:** É importante quando você deseja minimizar falsos positivos, ou seja, quando a identificação incorreta de casos positivos é crítica.

$$Precision = \frac{TP}{TP + FP}$$


Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$


$$Precision = \frac{TP}{TP + FP}$$




High Accuracy
Low Precision



High Accuracy
High Precision



Low Accuracy
Low Precision



Low Accuracy
High Precision

Metrics

➤ Accuracy (Acurácia):

- **Definição:** A acurácia mede a proporção de previsões corretas feitas por um modelo em relação ao número total de previsões.
- **Foco:** É uma métrica geral que avalia o desempenho global do modelo, levando em conta verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

➤ Precision (Precisão):

- **Definição:** A precisão mede a proporção de previsões positivas corretas em relação ao número total de previsões positivas feitas pelo modelo.
- **Foco:** É importante quando você deseja minimizar falsos positivos, ou seja, quando a identificação incorreta de casos positivos é crítica.

➤ Recall (Revocação):





- **Definição:** Recall, também conhecido como Sensibilidade ou Taxa de Verdadeiros Positivos, mede a capacidade de um modelo de identificar todos os exemplos **relevantes** em um conjunto de dados.
- **Foco:** É particularmente importante quando você deseja minimizar falsos negativos, ou seja, quando a não detecção de casos positivos é crítica.

Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$



Metrics

$$Accuracy = \frac{TP}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

➤ F1 Score:


- **Definição:** é uma métrica de avaliação que combina as métricas de precision e recall em um único número, fornecendo uma medida geral do desempenho de um modelo.
- **Foco:** é particularmente útil para encontrar um equilíbrio entre a precision e a capacidade de recuperar todos os casos positivos (recall). O F1 Score é calculado pela média harmônica da precision e recall.
- ❖ O F1 Score varia de 0 a 1, onde 1 indica um modelo perfeito que atinge tanto alta precisão quanto alta revocação.
- ❖ É especialmente útil quando as consequências de falsos positivos e falsos negativos são críticas e você deseja encontrar um equilíbrio entre esses dois tipos de erros.
- ❖ É amplamente utilizado em problemas de classificação binária, como detecção de spam, diagnóstico médico, ou classificação de sentimentos.

$$F1\ score = \frac{2 * Precision * Recall}{Precision + Recall} = \frac{TP}{TP + \frac{FP}{2} + \frac{FN}{2}}$$


Metrics

Confusion Matrix

- 150 samples (80% train + 20% test)
 - 3 classes (setosa, versicolor, virginica)
 - 30 test samples (test dataset):
 - ✓ Setosa – 11 samples (11 predicted)
 - ✓ Versicolor – 11 samples (10 predicted)
 - ✓ Virginica – 8 samples (9 predicted)
- 1 sample predicted Virginica => Versicolor (real)




Metrics



$$Accuracy = \frac{11 + 10 + 8}{11 + 11 + 8} = \frac{29}{30} = 0.9667$$

Metrics




Setosa: TP = 11 | FP = 0 | FN = 0
 Versicolor: TP = 10 | FP = 0 | FN = 1
 Virginica: TP = 8 | FP = 1 | FN = 0

$$\left\{ \begin{array}{l} Precision_{setosa} = \frac{11}{11 + 0} = \frac{11}{11} = 1 \\ Recall_{setosa} = \frac{11}{11 + 0} = \frac{11}{11} = 1 \end{array} \right.$$

$$\left\{ \begin{array}{l} Precision_{versicolor} = \frac{10}{10 + 0} = \frac{10}{10} = 1 \\ Recall_{versicolor} = \frac{10}{10 + 1} = \frac{10}{11} = 0.9091 \end{array} \right.$$

$$\left\{ \begin{array}{l} Precision_{virginica} = \frac{8}{8 + 1} = \frac{8}{9} = 0.8889 \\ Recall_{virginica} = \frac{8}{8 + 0} = \frac{8}{8} = 1 \end{array} \right.$$

Metrics



Setosa: TP = 11 | FP = 0 | FN = 0
 Versicolor: TP = 10 | FP = 0 | FN = 1
 Virginica: TP = 8 | FP = 1 | FN = 0

$$F1_{setosa} = \frac{2 * 1 * 1}{1 + 1} = \frac{2}{2} = 1$$

$$W_{setosa} = \frac{11}{30} = 0.3666$$


$$F1_{versicolor} = \frac{2 * 1 * 0.9091}{1 + 0.9091} = \frac{1.8182}{1.9091} = 0.9524$$

$$W_{versicolor} = \frac{11}{30} = 0.3666$$

$$F1_{virginica} = \frac{2 * 0.8889 * 1}{0.8889 + 1} = \frac{1.7778}{1.8889} = 0.9412$$

$$W_{virginica} = \frac{8}{30} = 0.2667$$

Metrics



Setosa: TP = 11 | FP = 0 | FN = 0

Versicolor: TP = 10 | FP = 0 | FN = 1

Virginica: TP = 8 | FP = 1 | FN = 0

$$F1\ score = \sum_{i=1}^n W_i * F1_i$$

$$F1\ score = (1 * 0.3666) + (0.9524 * 0.3666) + (0.9412 * 0.2667)$$

$$F1\ score = 0.9668$$

Daniel Nogueira

dnogueira@ipca.pt